

PHÁT HIỆN BẤT THƯỜNG TRONG DỮ LIỆU TÀI CHÍNH

Báo cáo thực hành lab 03

Nguyễn Minh Vũ Phùng Hoài Thi

Đại học Khoa học Tự nhiên, ĐHQG-HCM

Trí tuệ nhân tạo cho an ninh thông tin
Ngày 27 tháng 11 năm 2024

Tổng quan

- 1 Đánh giá công việc
- 2 Chuẩn bị dữ liệu
- 3 Khám phá Xử lý dữ liệu
Chọn đặc trưng
- 4 Tài liệu tham khảo

Đánh giá công việc

Yêu cầu	Phụ trách	Mức độ hoàn thành
Đọc dữ liệu	Vũ	100%
Xử lý dữ liệu	Vũ, Thi	100%
Cài đặt mô hình hồi quy logistic	Vũ	100%
Cài đặt mô hình	Thi, Vũ	100%
Viết báo cáo	Vũ, Thi	100%
Làm slide	Vũ, Thi	100%

Bảng 1: Bảng đánh giá công việc

Dữ liệu phân loại (category)

Đối với các biến dạng phân loại, nhóm áp dụng hai công cụ thống kê chính:

- **Kiểm định Chi-squared:** đánh giá mối liên hệ thống kê giữa từng biến phân loại với nhãn mục tiêu `RESULT_YES/NO`. Giá trị *p-value* được sử dụng để xác định ý nghĩa thống kê.
- **Cramér's V:** Trong khi Chi-squared cho biết “có liên hệ hay không” thì Cramér's V cho biết “liên hệ mạnh tới đâu”.

Kết quả phân tích

Bảng 2: Kết quả kiểm định Chi-squared và Cramér's V cho các biến phân loại


Biến phân loại	Chi-squared	<i>p-value</i>	Cramér's V
PRODUCT_NAME	806.54	2.12×10^{-82}	0.4016
ADDRESS_CURRENT	778.07	1.14×10^{-4}	0.3945
City	155.79	3.18×10^{-9}	0.1765
PROVINCE_CURRENT	155.79	3.18×10^{-9}	0.1765
EDUCATION	43.66	2.48×10^{-7}	0.0934
MARITAL_STATUS	17.53	1.52×10^{-3}	0.0592
GENDER	0.17	0.684	0.0058

Dữ liệu số (numeric)

Đối với các đặc trưng dạng số, nhóm tiến hành phân tích qua ba bước chính:

- Quan sát phân phối của các biến thông qua biểu đồ,
- Đánh giá độ lệch (skewness) để kiểm tra sự đối xứng của phân phối,
- Tính toán hệ số tương quan Spearman để xác định mối quan hệ giữa các biến số và nhãn mục tiêu `RESULT_YES/NO`. Các bước thực hiện cụ thể như sau:

Quan sát phân phối



Hình 1: Phân phối

Bảng 3: Độ lệch (skewness) của các biến số

biến số	skewness
term_tmp	14.72
loanamount_not_	
insurance	0.87
insurance_fee	0.91
la	0.88
eff_rate	-0.55
term	0.51
count_term_receipt	-0.25

biến số	skewness
sum_receipt_amt	1.29
emi	0.97
age	0.58
number_of_children	3.05
personal_income	4.49
additional_income	24.04
personal_expense	2.14
family_income	7.94
family_expense	2.78
income	4.46

Hệ số tương quan spearman

Bảng 4: hệ số tương quan spearman giữa các biến số và biến mục tiêu

biến số	spearman
count_term_receipt	0.1649
number_of_children	0.1442
income	0.1169
additional_income	0.0136
sum_receipt_amt	-0.0434
age	-0.0506
term_tmp	-0.0647
family_expense	-0.0983
app_id	-0.1131

biến số	spearman
personal_income	-0.1326
family_income	-0.1410
eff_rate	-0.1582
emi	-0.2363
insurance_fee	-0.3148
personal_expense	-0.3190
la	-0.3190
loanamount_not_	
insurance	-0.3193
term	-0.3478


- `REPORT_DATE`: Theo quan sát thì tất cả record đều chung một ngày báo cáo, vậy thuộc tính này chắc chắn không thể trực tiếp đóng góp vào model. Tuy nhiên từ đây ta có thể tính được từ ngày bắt đầu vay đến ngày báo cáo thông qua thuộc tính `DISBURSALDATE`.
- `DISBURSALDATE`: Tại đây tất cả các record đều chung tháng và năm. Ta sẽ kiểm tra tương quan giữa ngày với biến mục tiêu.

Bảng 5: Tương quan

Corr	Days
	-0.161

SVM One Class

Phương pháp này xây dựng một siêu phẳng (hyperplane) trong không gian đặc trưng để phân tách các điểm bình thường với các điểm bất thường.



Hình 2: Phân phối

Qua quá trình thử nghiệm và đo đạc, nhóm đã xác định được tập hợp các biến tối ưu nhất cho mô hình phát hiện bất thường khoản vay như sau:

- SUM_RECEIPT_AMT
- COUNT_TERM_RECEIPT
- TERM
- LA
- PRODUCT_NAME
- BAD_DEBT

- Dữ liệu ban đầu được tách thành:
 - **Phần dữ liệu bình thường:** Bao gồm tất cả các trường hợp được xác định là bình thường.
 - **Phần dữ liệu không bình thường:** Bao gồm các trường hợp bất thường (anomalies).
- Phần dữ liệu bình thường được chia tiếp theo tỷ lệ **8:2**:
 - **Dữ liệu huấn luyện (80%):** Dùng để huấn luyện mô hình SVM One-Class.
 - **Dữ liệu validation & test (20%):** Dùng để kiểm tra trong quá trình tối ưu tham số.
- Tập validation & test từ dữ liệu bình thường được gộp với dữ liệu không bình thường và chia theo tỷ lệ **50:50** để tạo thành:
 - **Tập kiểm tra (Test set):** Được dùng để đánh giá hiệu năng cuối cùng của mô hình.
 - **Tập kiểm định (Validation set):** Được dùng trong quá trình tìm kiếm tham số tối ưu.

Siêu tham số

Kernel *Radial Basis Function* (RBF) được áp dụng để chuyển đổi không gian đặc trưng. Hàm kernel được định nghĩa như sau:

$$K(x, x') = \exp \left(-\gamma \|x - x'\|^2 \right),$$

trong đó:

- x, x' : Là hai điểm dữ liệu trong không gian đặc trưng.
- $\gamma > 0$: Điều chỉnh độ rộng của kernel Gaussian.
 - Giá trị lớn của γ : Mô hình tập trung vào các điểm lân cận nhỏ.
 - Giá trị nhỏ của γ : Mở rộng phạm vi ảnh hưởng.

Tham số $\nu \in (0, 1]$ kiểm soát:

- Tỷ lệ lỗi tối đa được phép trong tập huấn luyện.
- Tỷ lệ support vectors được sử dụng trong mô hình.
- Giá trị ν lớn hơn sẽ làm tăng khả năng chấp nhận dữ liệu bất thường.

Tìm siêu tham số

Để tối ưu hiệu suất, hai tham số γ và ν được tìm kiếm thông qua phương pháp **Grid Search**:

- $\gamma \in \{10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 20, 25, 30\}$
- $\nu \in \{0.01, 0.05, 0.1, 0.2, 0.5\}$

Quá trình tìm kiếm được thực hiện trên tập kiểm định (validation set). Với mỗi cặp (γ, ν) , mô hình được huấn luyện và kiểm tra hiệu suất dựa trên các chỉ số:

- PR AUC (Precision-Recall Area Under Curve)
- Average Precision (AP)

Metric đánh giá

Chỉ số PR AUC đo lường diện tích dưới đường cong Precision-Recall, là một công cụ hữu ích trong bài toán phát hiện bất thường khi dữ liệu có sự mất cân bằng nghiêm trọng:

$$\text{PR AUC} = \int_0^1 \text{Precision } d(\text{Recall}).$$

Chỉ số Average Precision (AP) là trung bình trọng số của độ chính xác (Precision) tại các mức độ thu hồi (Recall) khác nhau:

$$\text{AP} = \sum_n (\text{Recall}_n - \text{Recall}_{n-1}) \times \text{Precision}_n,$$

trong đó Precision_n và Recall_n là các giá trị tại điểm n trong tập kết quả.


Hiệu năng tốt nhất của mô hình trên tập kiểm tra được tóm tắt trong bảng dưới đây.

Bảng 6: Hiệu năng tốt nhất của mô hình SVM One-Class trên tập kiểm tra

Tham số tối ưu	PR AUC	Average Precision (AP)	F1-Score
$\gamma = 25, \nu = 0.5$	0.85	0.73	0.88

Đường cong Precision-Recall

Hiệu năng tốt nhất của mô hình trên tập kiểm tra được tóm tắt trong bảng dưới đây.



Tài liệu tham khảo I

The End