

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



Thành viên

21120369 - Nguyễn Minh Vũ

21120558 - Phùng Hoài Thi

Báo cáo thực hành

Anomaly Detection using Unsupervised Learning

Giảng viên thực hành

ThS. Nguyễn Thị Hương

Thầy Nguyễn Ngọc Toàn

Tp. Hồ Chí Minh, tháng 11/2024

Mục lục

1	Nội dung thực hành	4
2	Khám phá và tiền xử lý dữ liệu	5
2.1	Khám phá dữ liệu	5
2.1.1	Chọn đặc trưng	5
2.1.2	Tiền xử lý dữ liệu	12
2.2	Mô hình SVM	13
2.2.1	Chọn đặc trưng	13
2.2.2	Chia dữ liệu	14
2.2.3	Kernel RBF	15
2.2.4	Tham số ν	15
2.2.5	Tìm kiếm tham số	15
2.2.6	Metric đánh giá	16
2.2.7	Kết quả và đánh giá	16
2.2.8	Bảng kết quả tốt nhất	16
2.2.9	Đánh giá hiệu quả	17

Danh sách hình

2.1	Phân phối dữ liệu của các biến số	7
2.2	Đường cong Precision-Recall (PR) của mô hình SVM One-Class	17

Danh sách bảng

1.1	Bảng đánh giá công việc	4
2.1	Kết quả kiểm định Chi-squared và Cramér's V cho các biến phân loại	6
2.2	Độ lệch (Skewness) của các biến số	8
2.3	Hệ số tương quan Spearman giữa các biến số và biến mục tiêu	10
2.4	Tương quan	11
2.5	Hiệu năng tốt nhất của mô hình SVM One-Class trên tập kiểm tra	16

Nội dung thực hành

Yêu cầu	Phụ trách	Mức độ hoàn thành
Đọc dữ liệu	Vũ	100%
Xử lý dữ liệu	Vũ, Thi	100%
Cài đặt mô hình	Vũ, Thi	100%
Viết báo cáo	Vũ, Thi	100%
Làm slide	Vũ, Thi	100%

Bảng 1.1: Bảng đánh giá công việc

Khám phá và tiền xử lý dữ liệu

2.1 Khám phá dữ liệu

2.1.1 Chọn đặc trưng

Trong bài toán này, hai phương pháp được áp dụng để chọn đặc trưng gồm: sử dụng công cụ thống kê và phương pháp Thử sai đặc trưng (RFE).

Dữ liệu phân loại (Categorical)

Đối với các biến dạng phân loại, nhóm áp dụng hai công cụ thống kê chính:

- **Kiểm định Chi-squared:** Kiểm định này được sử dụng để đánh giá mối liên hệ thống kê giữa từng biến phân loại với nhãn mục tiêu `RESULT_YES/NO`. Giá trị *p-value* được sử dụng để xác định ý nghĩa thống kê của mối quan hệ. Nếu *p-value* nhỏ hơn 0.05, biến đó được coi là có mối đáng kể với nhãn mục tiêu.
- **Cramér's V:** Được sử dụng để đo lường mức độ chặt chẽ của mối liên hệ giữa các biến phân loại và nhãn mục tiêu. Trong khi Chi-squared cho biết “có liên hệ hay không” thì Cramér's V cho biết “liên hệ mạnh tới đâu”.

Kết quả phân tích Bảng 2.1 tổng hợp kết quả của kiểm định Chi-squared và chỉ số Cramér's V đối với các biến phân loại trong tập dữ liệu. Dựa trên các kết quả này, nhóm đưa ra nhận xét và quyết định về việc giữ lại hay loại bỏ từng đặc trưng.

Bảng 2.1: Kết quả kiểm định Chi-squared và Cramér's V cho các biến phân loại

Biến phân loại	Chi-squared	<i>p-value</i>	Cramér's V
PRODUCT_NAME	806.54	2.12×10^{-82}	0.4016
ADDRESS_CURRENT_CITY	778.07	1.14×10^{-4}	0.3945
City	155.79	3.18×10^{-9}	0.1765
PROVINCE_CURRENT	155.79	3.18×10^{-9}	0.1765
EDUCATION	43.66	2.48×10^{-7}	0.0934
MARITAL_STATUS	17.53	1.52×10^{-3}	0.0592
GENDER	0.17	0.684	0.0058

Kết luận Dựa trên kết quả trong Bảng 2.1, các đặc trưng **PRODUCT_NAME** và **ADDRESS_CURRENT_CITY** có giá trị Cramér's V cao nhất (lần lượt là 0.4016 và 0.3945), thể hiện mối liên hệ mạnh với nhãn mục tiêu. Ngược lại, đặc trưng **GENDER** có giá trị Cramér's V rất thấp (0.0058) và *p-value* lớn hơn 0.05 (0.684), cho thấy không có mối liên hệ ý nghĩa thống kê với nhãn mục tiêu. Vì vậy, nhóm quyết định loại bỏ đặc trưng **GENDER** khỏi quá trình xây dựng mô hình.

Dữ liệu số (Numeric)


Đối với các đặc trưng dạng số, nhóm tiến hành phân tích qua ba bước chính:

- Quan sát phân phối của các biến thông qua biểu đồ,
- Đánh giá độ lệch (skewness) để kiểm tra sự đối xứng của phân phối,
- Tính toán hệ số tương quan Spearman để xác định mối quan hệ giữa các biến số và nhãn mục tiêu **RESULT_YES/NO**. Các bước thực hiện cụ thể như sau:

Quan sát phân phối dữ liệu Hình 2.1 thể hiện phân phối của các biến số trong dữ liệu. Qua biểu đồ, chúng tôi nhận thấy:

- Một số biến như **INCOME** có dạng gần chuẩn.

- Các biến như INSURANCE_FEE, EFF_RATE, và NUMBER_OF_CHILDREN có phân phối lệch phải đáng kể.
- Nhiều biến có giá trị tập trung tại một số điểm cụ thể, thể hiện sự bất đối xứng trong phân phối.



Hình 2.1: Phân phối dữ liệu của các biến số

Kiểm tra độ lệch (Skewness) Để đánh giá kỹ hơn tính đối xứng của phân phối, nhóm tính toán độ lệch (skewness) của từng biến số. Giá trị skewness tuyệt đối > 0.5 được xem là dấu hiệu cho thấy biến không phân phối chuẩn. Kết quả được trình bày trong Bảng 2.2.

Bảng 2.2: Độ lệch (Skewness) của các biến số

Biến số	Skewness
TERM_TMP	14.72
LOANAMOUNT_NOT_INSURANCE	0.87
INSURANCE_FEE	0.91
LA	0.88
EFF_RATE	-0.55
TERM	0.51
COUNT_TERM_RECEIPT	-0.25
SUM_RECEIPT_AMT	1.29
EMI	0.97
AGE	0.58
NUMBER_OF_CHILDREN	3.05
PERSONAL_INCOME	4.49
ADDITIONAL_INCOME	24.04
PERSONAL_EXPENSE	2.14
FAMILY_INCOME	7.94
FAMILY_EXPENSE	2.78
INCOME	4.46

Nhận xét về độ lệch (Skewness) Dựa trên kết quả trong Bảng 2.2, chúng tôi nhận thấy:

- **Phân phối gần chuẩn:** Một số biến như EFF_RATE (-0.55), và TERM (0.51) có độ lệch gần 0, cho thấy phân phối tương đối đối xứng và gần với phân phối chuẩn.
- **Phân phối lệch vừa phải:** Các biến như LOANAMOUNT_NOT_INSURANCE (0.87) và LA (0.88) có độ lệch vừa phải, biểu thị sự bất đối xứng không quá đáng kể.
- **Phân phối lệch mạnh:** Nhiều biến có độ lệch rất cao, cho thấy sự bất đối xứng nghiêm trọng, chẳng hạn:

- TERM_TMP (14.72) và ADDITIONAL_INCOME (24.04): Phân phối lệch phải rất nghiêm trọng.
- PERSONAL_INCOME (4.49), FAMILY_INCOME (7.94), và INCOME (4.46): Phân phối lệch phải mạnh.
- **Phân phối bất đối xứng nhẹ:** Biến SUM_RECEIPT_AMT (1.29) và NUMBER_OF_CHILDREN (3.05) có sự bất đối xứng đáng kể nhưng vẫn ở mức chấp nhận được trong phân tích.

Dựa trên kết quả này, nhóm kết luận rằng:

- Các biến có độ lệch rất cao (TERM_TMP, ADDITIONAL_INCOME) cần được xử lý bằng cách áp dụng các phép biến đổi như `logarithm`, `square root`, hoặc loại bỏ nếu cần thiết.
- Các biến như APP_ID và EFF_RATE có thể được giữ nguyên mà không cần xử lý thêm, do phân phối gần chuẩn.

Tính toán hệ số tương quan Spearman Do nhiều biến không tuân theo phân phối chuẩn, nhóm sử dụng hệ số tương quan Spearman để đo lường mối quan hệ giữa các biến số và nhãn mục tiêu RESULT_YES/NO. Spearman correlation dựa trên thứ hạng (rank) của các giá trị, do đó ít bị ảnh hưởng bởi sự bất đối xứng trong phân phối. Kết quả được trình bày trong Bảng 2.3.

Bảng 2.3: Hệ số tương quan Spearman giữa các biến số và biến mục tiêu

Index	Variable	Spearman Correlation
1	COUNT_TERM_RECEIPT	0.1649
2	Number_of_Children	0.1442
3	INCOME	0.1169
4	ADDITIONAL_INCOME	0.0136
5	SUM_RECEIPT_AMT	-0.0434
6	AGE	-0.0506
7	TERM_TMP	-0.0647
8	FAMILY_EXPENSE	-0.0983
9	APP_ID	-0.1131
10	PERSONAL_INCOME	-0.1326
11	FAMILY_INCOME	-0.1410
12	EFF_RATE	-0.1582
13	EMI	-0.2363
14	INSURANCE_FEE	-0.2809
15	PERSONAL_EXPENSE	-0.3148
16	LA	-0.3190
17	LOANAMOUNT_NOT_INSURANCE	-0.3193
18	TERM	-0.3478

Nhận xét Dựa trên kết quả trong Bảng 2.3, chúng tôi nhận thấy:

- **Các biến có mối quan hệ dương (tương quan tích cực):**

- Biến COUNT_TERM_RECEIPT (0.1649) và Number_of_Children (0.1442) có hệ số tương quan Spearman dương cao nhất, mặc dù mức độ tương quan vẫn khá yếu.
- Biến INCOME (0.1169) có mức độ tương quan dương nhẹ với biến mục tiêu.

- **Các biến có mối quan hệ âm (tương quan nghịch):**

- Các biến như TERM (-0.3478), LOANAMOUNT_NOT_INSURANCE (-0.3193), và PERSONAL_EXPENSE (-0.3148) có hệ số tương quan âm cao nhất, thể hiện mối liên hệ nghịch đáng kể với biến mục tiêu.
- Nhiều biến như INSURANCE_FEE (-0.2809), LA (-0.3190), và EFF_RATE (-0.1582) cũng có tương quan nghịch nhưng ở mức trung bình hoặc yếu.

- **Các biến có tương quan không đáng kể:**

- Biến `ADDITIONAL_INCOME` (0.0136) có hệ số tương quan gần như bằng 0, thể hiện mối quan hệ rất yếu hoặc không đáng kể với biến mục tiêu.
- Các biến như `SUM_RECEIPT_AMT` (-0.0434) và `AGE` (-0.0506) cũng thể hiện mối quan hệ không rõ ràng.

Kết luận Từ bảng và nhận xét trên, nhóm kết luận rằng:

- Các biến như `COUNT_TERM_RECEIPT`, `Number_of_Children`, và `TERM` có thể được giữ lại trong mô hình do có mức độ tương quan đáng kể với biến mục tiêu.
- Các biến có hệ số tương quan rất thấp như `ADDITIONAL_INCOME` và `SUM_RECEIPT_AMT` có thể được xem xét loại bỏ để giảm độ phức tạp của mô hình.

Dữ liệu Datetime

- `REPORT_DATE`: Theo quan sát thì tất cả record đều chung một ngày báo cáo, vậy thuộc tính này chắc chắn không thể trực tiếp đóng góp vào model. Tuy nhiên từ đây ta có thể tính được từ ngày bắt đầu vay đến ngày báo cáo thông qua thuộc tính `DISBURSALDATE`.
- `DISBURSALDATE`: Tại đây tất cả các record đều chung tháng và năm. Ta sẽ kiểm tra tương quan giữa ngày với biến mục tiêu.

Bảng 2.4: Tương quan

Corr	Days
	-0.161

Kết luận Có rất ít sự tương quan giữa các biến datetime với biến mục tiêu, xem xét loại bỏ hoặc không ưu tiên.

2.1.2 Tiền xử lý dữ liệu

Xử lý dữ liệu thiếu

Thông qua các hàm được cung cấp sẵn trong python, ta xác định được 3 cột tồn tại giá trị thiếu:

- **Number of Children:** N/A là không có con vì vậy điền giá trị 0
- **COUNT_TERM_RECEIPT** và **SUM_RECEIPT_AMT:** N/A là nợ xấu không trả, vì vậy giá trị hiển nhiên là 0, bên cạnh đó ta cần khai thác điểm này bằng cách tạo thêm cột nhị phân **BAD_DEBT** mang ý nghĩa nợ xấu.

Khi dùng model thực tế, các biến bị thiếu sẽ được xử lý như sau:

- **TERM:** Được thay thế bởi giá trị trung bình từ tập huấn luyện.
- **LA:** Được thay thế bởi giá trị trung bình từ tập huấn luyện.
- **PRODUCT_NAME:** Nếu có giá trị product chưa xuất hiện trong tập huấn luyện hoặc không có product, thay bằng 0.

Xử lý dữ liệu không nhất quán

Xử lý bằng cách cắt ngưỡng (capping), thay thế bằng giá trị trung bình.

Chuẩn hóa biến

Xác định lại định dạng

- **RESULT_YES/NO:** Định dạng lại thành biến category phục vụ cho mô hình classification.

Mã hóa biến category

- **PRODUCT_NAME:** Dùng kỹ thuật **Frequency encoding**, Vì không có thứ tự cụ thể cũng như tương lai có thể xuất hiện các product mới.

Mã hóa biến numeric Tất cả các biến `TERM`, `SUM_RECEIPT_AMT`, `COUNT_TERM_RECEIPT` và `LA` được chuẩn hóa về phân phối chuẩn bằng cách trừ đi trung bình và chia cho độ lệch chuẩn.

Tạo thuộc tính mới

Dựa vào 2 cột `COUNT_TERM_RECEIPT` và `SUM_RECEIPT_AMT` ta biết được thông tin về nợ xấu, vì vậy có thể tạo một thuộc tính nhị phân mới tên `BAD_DEBT`, mang giá trị 1 tại nơi 2 cột trên N/A, và 0 ở những nơi còn lại.

2.2 Mô hình SVM

Mô hình **SVM One-Class** được sử dụng để phát hiện bất thường trong dữ liệu các khoản vay. Phương pháp này xây dựng một siêu phẳng (hyperplane) trong không gian đặc trưng để phân tách các điểm bình thường với các điểm bất thường.

2.2.1 Chọn đặc trưng

Qua quá trình thử nghiệm và đo đạc, nhóm đã xác định được tập hợp các biến tối ưu nhất cho mô hình phát hiện bất thường khoản vay như sau:

- `SUM_RECEIPT_AMT`: Phản ánh khả năng thanh toán của khách hàng. Số tiền đã trả càng thấp hoặc không có giao dịch nào càng có thể là dấu hiệu bất thường.
- `COUNT_TERM_RECEIPT`: Kết hợp với thời hạn vay (`TERM`) để xác định sự bất thường trong số kỳ hạn đã thanh toán. Số kỳ hạn quá thấp hoặc không tương ứng với thời hạn vay có thể là tín hiệu bất thường.
- `TERM`: Yếu tố quyết định cấu trúc khoản vay. Sự không khớp giữa thời hạn vay và lịch sử thanh toán (`SUM_RECEIPT_AMT` hoặc `COUNT_TERM_RECEIPT`) giúp phát hiện các khoản vay không đúng quy tắc.
- `LA`: Đóng vai trò quan trọng trong việc đánh giá quy mô khoản vay. Khoản vay có giá trị không phù hợp với đặc điểm khách hàng (ví dụ: thu nhập thấp nhưng khoản vay lớn) có thể là bất thường.

- **PRODUCT_NAME:** Mã định danh giúp phân biệt từng loại sản phẩm khoản vay. Dựa vào đó, mô hình có thể so sánh hành vi thanh toán với hành vi điển hình của từng sản phẩm, từ đó phát hiện bất thường.
- **BAD_DEBT:** Phản ánh trực tiếp tình trạng nợ xấu. Sử dụng biến này giúp mô hình học được mối quan hệ giữa các đặc điểm khoản vay và khả năng thuộc nhóm bất thường.

2.2.2 Chia dữ liệu

Dữ liệu được phân chia như sau:

- Dữ liệu ban đầu được tách thành:
 - **Phần dữ liệu bình thường:** Bao gồm tất cả các trường hợp được xác định là bình thường.
 - **Phần dữ liệu không bình thường:** Bao gồm các trường hợp bất thường (anomalies).
- Phần dữ liệu bình thường được chia tiếp theo tỷ lệ **8:2**:
 - **Dữ liệu huấn luyện (80%):** Dùng để huấn luyện mô hình SVM One-Class.
 - **Dữ liệu validation & test (20%):** Dùng để kiểm tra trong quá trình tối ưu tham số.
- Tập validation & test từ dữ liệu bình thường được gộp với dữ liệu không bình thường và chia theo tỷ lệ **50:50** để tạo thành:
 - **Tập kiểm tra (Test set):** Được dùng để đánh giá hiệu năng cuối cùng của mô hình.
 - **Tập kiểm định (Validation set):** Được dùng trong quá trình tìm kiếm tham số tối ưu.

2.2.3 Kernel RBF

Kernel *Radial Basis Function* (RBF) được áp dụng để chuyển đổi không gian đặc trưng. Hàm kernel được định nghĩa như sau:

$$K(x, x') = \exp(-\gamma \|x - x'\|^2),$$

trong đó:

- x, x' : Là hai điểm dữ liệu trong không gian đặc trưng.
- $\gamma > 0$: Điều chỉnh độ rộng của kernel Gaussian. Giá trị lớn của γ làm mô hình tập trung vào các điểm lân cận nhỏ, trong khi giá trị nhỏ hơn mở rộng phạm vi ảnh hưởng.

2.2.4 Tham số ν

Tham số $\nu \in (0, 1]$ kiểm soát:

- Tỷ lệ lỗi tối đa được phép trong tập huấn luyện.
- Tỷ lệ support vectors được sử dụng trong mô hình.

Giá trị ν lớn hơn sẽ làm tăng khả năng chấp nhận dữ liệu bất thường.

2.2.5 Tìm kiếm tham số

Để tối ưu hiệu suất, hai tham số γ và ν được tìm kiếm thông qua phương pháp **Grid Search**:

- $\gamma \in \{10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 20, 25, 30\}$
- $\nu \in \{0.01, 0.05, 0.1, 0.2, 0.5\}$

Quá trình tìm kiếm được thực hiện trên tập kiểm định (validation set). Với mỗi cặp (γ, ν) , mô hình được huấn luyện và kiểm tra hiệu suất dựa trên các chỉ số PR AUC và Average Precision.

2.2.6 Metric đánh giá

PR AUC (Precision-Recall Area Under Curve)

Chỉ số PR AUC đo lường diện tích dưới đường cong Precision-Recall, là một công cụ hữu ích trong bài toán phát hiện bất thường khi dữ liệu có sự mất cân bằng nghiêm trọng. Công thức tính PR AUC:

$$\text{PR AUC} = \int_0^1 \text{Precision} d(\text{Recall}).$$

Average Precision (AP)

Chỉ số Average Precision (AP) là trung bình trọng số của độ chính xác (Precision) tại các mức độ thu hồi (Recall) khác nhau:

$$\text{AP} = \sum_n (\text{Recall}_n - \text{Recall}_{n-1}) \times \text{Precision}_n,$$

trong đó Precision_n và Recall_n là các giá trị tại điểm n trong tập kết quả.

2.2.7 Kết quả và đánh giá

Đường cong Precision-Recall


Đường cong Precision-Recall (PR) được sử dụng để đánh giá hiệu năng mô hình trên tập kiểm tra. Đồ thị dưới đây biểu diễn mối quan hệ giữa Precision và Recall.

2.2.8 Bảng kết quả tốt nhất

Hiệu năng tốt nhất của mô hình trên tập kiểm tra được tóm tắt trong bảng dưới đây.

Bảng 2.5: Hiệu năng tốt nhất của mô hình SVM One-Class trên tập kiểm tra

Tham số tối ưu	PR AUC	Average Precision (AP)	F1-Score
$\gamma = 25, \nu = 0.5$	0.85	0.73	0.88



Hình 2.2: Đường cong Precision-Recall (PR) của mô hình SVM One-Class

2.2.9 Đánh giá hiệu quả

Dựa trên kết quả trong Bảng 2.5, cặp tham số tối ưu $\gamma = 25, \nu = 0.5$ đạt hiệu suất cao nhất với PR AUC là 0.85 và Average Precision là 0.73. Đường cong Precision-Recall (Hình 2.2) minh họa khả năng duy trì độ chính xác cao trên toàn bộ phổ Recall, khẳng định hiệu quả của mô hình trong việc phát hiện bất thường.