

LAB 4 – BẢO MẬT TRONG QUÁ TRÌNH HUẤN LUYỆN MÔ HÌNH MÁY HỌC

1. Mô hình Federated learning.

Tái sử dụng lại mô hình đã được xây dựng ở Lab2. Yêu cầu các nhóm xây dựng mô hình có hiệu suất dưới 70% điều chỉnh lại mô hình để hiệu suất đạt trên 70%. Vì khi áp dụng các cách phòng thủ, hiệu suất sẽ giảm. Vì vậy hiệu suất của base model tốt từ đầu để sau khi áp dụng cách phòng thủ thì khi huấn luyện mô hình vẫn hội tụ được và ra được kết quả chấp nhận được.

Yêu cầu:

- *Tinh chỉnh lại mô hình lab2 để đạt hiệu suất cao hơn 70% (1đ)*

2. Bảo vệ mô hình.

Tương ứng với phần xây dựng mô hình tấn công ở Lab2. Ở Lab4 này chúng ta sẽ xây dựng mô hình bảo vệ mô hình Federated learning tương ứng với mô hình tấn công đã tìm hiểu ở Lab2.

Phần phòng thủ sẽ chia làm 3 phần:

a. Phòng thủ tại Client.

Người tấn công là server với mục tiêu: Truy cập, sao chép, hoặc chia sẻ dữ liệu người dùng ở client.

Gợi ý một số cách để phòng thủ trường hợp này cần:

- Mã hóa dữ liệu và mô hình.
- Tách biệt dữ liệu và mô hình.
- Kiểm thử ngẫu nhiên

b. Phòng thủ tại Server.

Người tấn công là một trong các client tham gia vào quá trình huấn luyện mô hình FL.

Người tấn công có thể giả mạo client hoặc lợi dụng quyền hạn của client để:

- *Data Poisoning Attack*: Gửi dữ liệu đào tạo sai lệch để ảnh hưởng đến mô hình chung.
- *Model Poisoning*: Sửa đổi gradient hoặc mô hình cục bộ trước khi gửi về server, làm hỏng mô hình tổng hợp.

- *Privacy Leakage*: Truy cập các mô hình hoặc gradient để suy luận về dữ liệu của các client khác.

Đối với trường hợp này, gợi ý một số cách để hệ thống phòng thủ cần:

- Thiết kế bảo mật ngay từ đầu
- Giám sát liên tục
- Cập nhật mô hình thường xuyên
- Kết hợp nhiều biện pháp

c. Phòng thủ đối với người tấn công là người ngoài hệ thống.

Người ngoài hệ thống cố gắng khôi phục hoặc nhái lại mô hình (gồm trọng số và cấu trúc) đã được huấn luyện bằng cách tấn công model stealing.

Người tấn công gửi hàng loạt truy vấn đến mô hình để tái tạo một phiên bản tương tự mô hình gốc.

Sử dụng mô hình được truy cập ((hoặc trích xuất) để suy ra thông tin nhạy cảm từ dữ liệu đào tạo. Ví dụ: Tấn công mô hình để xác định xem một cá nhân cụ thể có trong dữ liệu đào tạo hay không

Gợi ý cho người phòng thủ là người cung cấp dịch vụ (server) cần:

- Xác thực đầu vào truy vấn tới mô hình.
- Làm mờ kết quả đầu ra: Thêm nhiễu hoặc ẩn một phần đầu ra của mô hình để giảm rủi ro trích xuất mô hình hoặc suy luận dữ liệu.
- Thêm nhiễu: Thêm nhiễu vào kết quả dự đoán của mô hình để đảm bảo dữ liệu gốc không thể bị suy luận.

Yêu cầu:

- Nhóm 1 – 7: Phòng thủ tại Server (Lab 2 các bạn làm Adversarial Examples)
- Nhóm 8 – 14: Phòng thủ tại Client (Lab 2 các bạn làm Membership Inference Attacks)
- Các nhóm còn lại: Phòng thủ đối với người tấn công là người ngoài hệ thống (Lab 2 các bạn làm Model Stealing Attacks).
- *Viết báo cáo (3đ)*
- *Lập trình mô hình phòng thủ với hiệu suất đạt trên 60% (6đ)*

3. Các yêu cầu khác

- Ngôn ngữ sử dụng bắt buộc là Python, không được phép sử dụng ngôn ngữ khác.
- Không giới hạn thư viện được sử dụng trong Python.
- Các nhóm cần kiểm tra mã nguồn trước khi nộp. Nếu mã nguồn không chạy được mà không phải do nguyên nhân khách quan (thiếu thư viện, lỗi do thư viện gây ra, sử dụng thư viện sai phiên bản, ...) thì sẽ bị 0 điểm đồ án.

Bài nộp gồm có 3 phần:

- Report: chứa các file báo cáo.
- Source: Chứa các file mã nguồn.
- Presentation: Chứa các file dùng để thuyết trình.
- Trong file nộp, nhóm cần ghi rõ thông tin các thành viên gồm họ tên và MSSV. Riêng đối với mã nguồn, nhóm có thể ghi thông tin trên dưới dạng comment trong code của nhóm.
- Bài nộp sẽ được đặt trong thư mục có tên MSSV01[_MSSV02_[MSSV03[...]]] và được nén lại bằng định dạng ZIP với cùng tên như trên. Ví dụ đặt tên nhóm 1 có 1 sinh viên là MSSV01, nhóm có 2 sinh viên là MSSV01_MSSV02.
- Nghiêm cấm hành vi gian lận, không trung thực trong học tập như sao chép bài làm giữa các nhóm với nhau, sao chép bài làm của các nhóm khóa trước hoặc các nhóm lớp khác trường khác, nhờ người làm hộ. Nếu phát hiện các hành vi thì cả nhóm sẽ bị 0 điểm và xử lý theo quy định của Khoa và Trường.