

BẢO MẬT TRONG QUÁ TRÌNH HUẤN LUYỆN MÔ HÌNH MÁY HỌC

Báo cáo thực hành lab 03

Nguyễn Minh Vũ Phùng Hoài Thi

Đại học Khoa học Tự nhiên, ĐHQG-HCM

Trí tuệ nhân tạo cho an ninh thông tin
Ngày 6 tháng 12 năm 2024

Tổng quan

- 1 Đánh giá công việc
- 2 Tấn công
- 3 Phòng thủ
- 4 Tài liệu tham khảo

Yêu cầu	Phụ trách	% hoàn tất
Điều chỉnh mô hình đạt hiệu suất $\geq 70\%$	Vũ	100%
Mô phỏng kiểu tấn công Data Poisoning	Vũ	100%
Mô phỏng kiểu tấn công Model Poisoning	Vũ	100%
Mô phỏng phòng thủ tại Server	Thi	100%

Bảng 1: Bảng đánh giá công việc

Data Poisoning

Data Poisoning là cách tấn công mà người tấn công (malicious user) là 1 trong các client được kết nối với mô hình học liên kết. Khi này, người tấn công có khả năng làm sai lệch dữ liệu huấn luyện ở local dẫn đến mô hình huấn luyện đạt kết quả kém và truyền trọng số kém đó cho máy chủ tổng hợp (server) làm ảnh hưởng đến việc tính toán trọng số chung của máy chủ.

Model Poisoning

Model Poisoning là một kiểu tấn công khác mà tại đó, người tấn công thay vì xâm nhập vào trong dữ liệu thì sẽ cố tình làm sai lệch các tính toán trọng số tại Client trước khi gửi lên Server. Server khi nhận được trọng số này sẽ tổng hợp và làm ảnh hưởng chung đến cả quá trình huấn luyện học liên kết.

Thử nghiệm tấn công

Method	Client 0	Client 1	Client 2	Server
data0-012	20.54%	70.32%	69.36%	73.66%
	270.1454	35.4463	14.4910	74.3384
data1-012	43.00%	54.70%	68.30%	68.60%
	371.4643	107.2137	16.1385	110.6368
data2-012	46.54%	69.88%	51.82%	61.38%
	193.0082	42.1704	59.4833	121.9774
model0	43.82%	66.46%	71.80%	73.26%
	263.7077	40.5621	19.8870	95.4963
model1	42.86%	65.62%	68.94%	69.02%
	277.8181	54.4610	30.3182	130.6952
model2	43.80%	66.24%	69.56%	64.94%
	282.6458	59.7970	34.1861	150.1995

Bảng 2: Accuracy và Loss khi áp dụng các tấn công vào mô hình

Phương Pháp: Mean Trimmed

- **Giảm ảnh hưởng của outliers:** Loại bỏ một phần nhỏ các giá trị cực trị khi tính trung bình.
- **Cách thức hoạt động:**
 - Client gửi các cập nhật tới server.
 - Server loại bỏ các giá trị cực trị (5% hoặc 10%).
 - Tính toán lại giá trị trung bình và cập nhật mô hình.
- **Ưu điểm:** Giảm tác động của tấn công mà không mất dữ liệu quan trọng.

Phương Pháp: L2 Regularization

- **Giảm tác động của trọng số lớn:** Điều chuẩn trọng số để ngăn ngừa thay đổi quá mức.
- **Cách thức hoạt động:**
 - Hàm mất mát:

$$L = L_{\text{original}} + \lambda \sum_{i=1}^n w_i^2$$

- λ là hệ số điều chuẩn.
- **Ưu điểm:** Giữ trọng số ổn định, giảm ảnh hưởng từ các gradient sai lệch.

Phương Pháp: Cosine Similarity

- **Đo lường sự tương đồng giữa các client:** Tính toán cosine similarity giữa các trọng số.
- **Cách thức hoạt động:**
 - Cosine similarity giữa các client i và j :

$$\text{sim}(i, j) = \frac{w_i \cdot w_j}{\|w_i\| \|w_j\|}$$

- **Ưu điểm:** Ưu tiên cập nhật từ những client có mô hình tương đồng, giảm thiểu ảnh hưởng từ các client bị tấn công.

Thử nghiệm phòng thủ


Defense	Client 0	Client 1	Client 2	Server
mean	47.86%	72.16%	69.90%	74.22%
	184.1569	24.5191	15.9685	61.8961
trim	47.48%	71.64%	78.44%	78.42%
	138.7201	41.7406	19.8166	26.2839
triml2	39.76%	61.40%	74.26%	75.38%
	110.6644	21.3976	15.0574	9.9881

Bảng 3: Accuracy và độ Loss khi áp dụng các phương pháp phòng thủ.


Thử nghiệm tấn công khi có phòng thủ

Method	Client 0	Client 1	Client 2	Server
Hyperparameter: L2 = 0.00005, Trim = 0.05				
data0-012-trim	21.26%	68.98%	78.44%	78.28%
	211.3589	35.1035	19.9106	35.3388
data1-012-triml2	20.54%	73.22%	78.68%	78.60%
	307.2370	36.6946	18.6949	35.5304
data2-012-trim	43.50%	57.42%	78.32%	78.26%
	361.0038	145.2158	18.8239	50.6362
model0-triml2	42.64%	69.36%	75.68%	74.68%
	271.8670	59.0393	40.5174	60.7272
model1-triml2	43.20%	68.84%	73.74%	73.28%
	276.4293	100.0227	65.4308	91.2567
model2-triml2	45.50%	68.06%	72.02%	70.60%
	258.1499	90.4595	74.3402	99.1544

Bảng 4: Accuracy và Loss khi áp dụng phòng thủ trước các tấn công vào mô hình



Hình 1: So sánh Accuracy khi áp dụng kiểu tấn công Data Poisoning vào Client 2 khi có phòng thủ Trim



Hình 2: So sánh Accuracy khi áp dụng kiểu tấn công Model Poisoning vào Client 2 khi có phòng thủ Trim-L2

Nick Galanis. *Defending against Data Poisoning Attacks in Federated Learning via User Elimination*. 2024. arXiv:2404.12778 [cs.CR].

Available at: <https://arxiv.org/abs/2404.12778>.

Kai Li et al. *Data-Agnostic Model Poisoning against Federated Learning: A Graph Autoencoder Approach*. 2023. arXiv:2311.18498 [cs.LG]. Available at: <https://arxiv.org/abs/2311.18498>.

Gan Sun et al. *Data Poisoning Attacks on Federated Machine Learning*. IEEE Internet of Things Journal, 9.13 (2021), pp. 11365–11375.

The End